

# Programming Assignment 4

執行環境: Visual Studio Code

程式語言: Python 3.11.5

作業架構:

R12725048

- |— report.pdf
- |— 8.txt
- |— 13.txt
- |— 20.txt
- |— pa4.py

# 執行方式

- 使用VS code跑pa4.py檔
- 需要下載的套件有:
  - `pip install nltk`: 刪除stopwords及使用Porter' s algorithm.  
所需
- 直接按全部執行即可

# 處理邏輯

- Step 1 : import 所需套件

```
11  import re
12  import math
13  import numpy as np
14  import pandas as pd
15  from os import listdir
16  from nltk.stem import PorterStemmer
17  from nltk.corpus import stopwords
```

# 處理邏輯

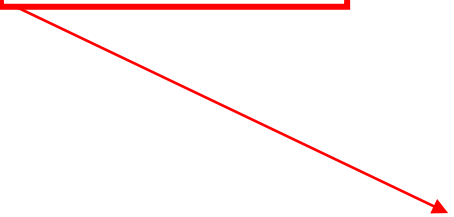
- Step 2 : 根據前作業 一樣先依據上次的dataset為每個doc建立其 tfidf vector
  - 此步驟會做資料的前處理、建好dictionary、tf-idf table
  - 皆是上次作業的內容，因此簡報就不多花篇幅敘述

```
192 # Get TF and DF
193 # Term frequency list: [[id, {word: tf, ...}], ...]
194 # Document frequency dictionary: {word: df}
195 tf_list, df_dict = get_tf_and_df(corpus)
196
197 # Get Index Dictionary
198 # Index Dictionary: {Word: Index}
199 index_dict = get_index_dict(df_dict)
```

# 處理邏輯

- Step 3 : 計算兩兩documents的cosine similarity
  - 記錄到C Matrix

```
247 # Get cosine similarity array
248 C = np.array([[cosine(doc_x, doc_y) for doc_x in range(1, DOC_SIZE+1)] for doc_y in range(1, DOC_SIZE+1)])
```



```
163 def cosine(doc_x, doc_y):
164     vector_x = extract_vector(doc_x, doc_vectors)
165     vector_y = extract_vector(doc_y, doc_vectors)
166     cosine_sim = float(np.dot(vector_x, vector_y))
167     return cosine_sim
```

# 處理邏輯

- Step 4 : 初始化A、I array

- I:紀錄每個doc的存活狀態
- A:紀錄每次merge是將哪兩個cluster合併的

```
254     I = np.array([1]* DOC_SIZE)
255
256
      Run Cell | Run Above | Debug Cell
257     # In[13]:
258
259
260     A = []
```

# 處理邏輯

- Step 5 :並用complete link的方式建構HAC

- 先取出具有最大相似的的兩群
- 再更新C Matrix:用這兩群中最遠的兩點作為新的相似度
- 將I[m]設為0，因為已經被併到cluster i了

```
266     for k in range(DOC_SIZE-1):
267         i, m = get_max_similarity(C, I, DOC_SIZE)
268         A.append([i, m])
269         for j in range(DOC_SIZE):
270             C[i][j] = min(cosine(i, j), cosine(m, j))
271             C[j][i] = min(cosine(j, i), cosine(j, m))
272         I[m] = 0
```

# 處理邏輯

- Step 6 :以bottom-up的方式建構HAC，並將cluster數分別為K = 8, 13, and 20的時候輸出txt檔

```
278 hac_dict = {str(i) : [i] for i in range(DOC_SIZE)}
279 for doc_i, doc_m in A:
280     new_element = hac_dict[str(doc_m)]
281     hac_dict.pop(str(doc_m))
282     hac_dict[str(doc_i)] += new_element
283     if len(hac_dict) == 20:
284         write_result(hac_dict, 20)
285     if len(hac_dict) == 13:
286         write_result(hac_dict, 13)
287     if len(hac_dict) == 8:
288         write_result(hac_dict, 8)
```