

Programming Assignment 2

執行環境: Visual Studio Code
程式語言: Python 3.11.5

執行方式

- 使用VS code跑pa2.py檔
- 需要下載的套件有:
 - `pip install stop_words`: 刪除不太帶有資訊的單詞所需
 - `pip install nltk`: 使用Porter' s algorithm.所需
- 直接按全部執行即可
- 第三題會需要user輸入兩個數字，分別是想計算兩篇文章的id

```
請輸入你想計算哪兩篇Documents的cosine similarity
第一篇(輸入一個數字): 55
第二篇(輸入一個數字): 88
0.35948836382771504
```

處理邏輯

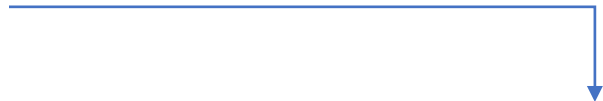
- Step 1 : import 所需套件

```
2  import math
3  from nltk.stem import PorterStemmer
4  import re
5  from stop_words import get_stop_words
```

處理邏輯

- Step 2 : 建立class TF_TFIDF()，並建立其object : tf_idf
將tf_idf的attributes&methods初始化

```
106  tf_idf = TF_IDF()
```



```
7  class TF_IDF():
8      def __init__(self):
9          self.path = "./IRTM"
10         self.num_docs = 1095 #文章數
11         self.token_list = [[] for i in range(self.num_docs+1)] #token_list記錄每篇文章tokenization後的term
12         self.allwords = []
13         self.stopword = []
14         self.Tokenization() # step1 先將所有文章進行tokenization
15         self.tf = []
16         self.df = {}
17         self.idf = {}
18         self.tfidf_unit_vector = []
19         self.bow = {}
20         self.cal_tfidf() #step 2 計算tfidf
```

處理邏輯

將一些換行符號、逗點等等以re.sub() function先清除掉
再將剩下的字元全部轉換成小寫
最後用split的方式做tokenize並存入token_list中

• Step 3 : Tokenization

```
38 #<-----Tokenization----->
39 # Tokenization會呼叫2個functions
40 # 1.removeStopWord 2.Stemming
41 def Tokenization(self):
42
43     #處理從第1篇~第1095篇文章
44     for i in range(1,self.num_docs+1):
45         #讀檔
46         file_path = self.path+"/"+str(i)+".txt"
47         f = open(file_path,'r')
48         doc = f.read()
49
50         doc = re.sub('\n', ' ', doc) #移除換行符號
51         doc = re.sub('[^A-Za-z\']+', ' ', doc) #只留下英文&'的字元
52         doc = doc.lower() #將所有英文字元都轉為小寫
53
54         filtered_string = self.removeStopWord(doc) #移除stopwords
55         filtered_string = re.sub('\'', ' ', filtered_string) #再把還有"'"的地方清掉
56         filtered_string = re.sub(r'\b\w{1}\b', ' ', filtered_string) #把有些被濾到只剩一個char的字串刪掉
57         filtered_string = re.sub(' +', ' ', filtered_string) #把有連續>=2個white space的地方改成一格就好
58         filtered_string = filtered_string.strip() #把文章前後的空白刪掉
59         token = filtered_string.split(' ') #以空白鍵來分割文字成token
60         self.token_list[i] = self.Stemming(token) #用Porter's algorithm 來進行Stemming
```

這裡留下 " ' 符號先不刪掉，是為了等一下要移除 stopwords時比較好清，因為stopwords裡有很多像是 don 't、didn' t等字

處理邏輯

- Step 3(1) : Stopwords removal

將參數str中含有stopwords的字過濾掉，再傳回去

```
30      #<-----remove stop words----->
31  ✓   def removeStopWord(self, str):
32
33       stopwords = get_stop_words('en')
34       text = ' '.join([word for word in str.split() if word not in stopwords])
35
36       return(text)
```

處理邏輯

- Step 3(2) : Stemming using Porter' s algorithm

利用PorterStemmer套件進行stemming
並將處理完的token放入word，以List的格式回傳
最後stemming完的字會被放到token_list[i]中，而i為document id

```
22         #<-----Stemming----->
23         def stemming(self, tokens):
24             ps = PorterStemmer()
25             word = []
26             for token in tokens:
27                 word.append(ps.stem(token))
28             return word
```

處理邏輯

- Step 4 : 計算tf、df、idf

```
63 """
64 計算tf,idf結果
65 tf:[{word1:3,word2:4,word4:2},{word2:5,word3:7, word4:2},{....},.....]
66 df:{word1:{df:6個doc, t_index:1},word2:{df:3個doc, t_index:2},word3:{df:5個doc, t_index:3},word4:{df:4個doc, t_index:4}.....}
67 idf:{word1:idf(word1),word2:idf(word2),word3:idf(word3).....}
68 """
69 def cal_tfidf(self):
70     #處理從第1篇~第1095篇文章
71     for i in range(1,self.num_docs+1):
72         bow = {} #bow為暫存doc[i]所有term的term frequency ex.bow:{word1:5, word2:7,...}
73         for word in self.token_list[i]: #遍歷doc[i]其token_list 計算每個word在doc[i]的出現次數
74             if not word in bow:
75                 bow[word] = 0
76                 bow[word] += 1
77         self.tf.append(bow) #加到tf中，tf以List方式記錄每個doc的term freq.
78         for word in bow.keys(): #遍歷bow.keys()(也就是doc[i]的set(token_list[i])) 計算每個word在所有doc中 總共出現在幾篇doc
79             if word not in self.df:
80                 self.df[word] = {}
81                 self.df[word]['df'] = 0
82                 self.df[word]['df'] += 1
83         self.df = dict(sorted(self.df.items())) #將df依term排序好
84         #計算df裡的term其idf值 idf = log10(N/df)
85         for word in self.df.keys():
86             self.idf[word] = math.log10(self.num_docs / self.df[word]['df'])
87
```


處理邏輯

- Step 5 : 回答第一題 建立dictionary.txt

```
113 # (1) Construct a dictionary
114 path = './dictionary.txt'
115 f = open(path, 'w')
116 row = 0
117 print("{:<8} {:<12} {:<8}".format('t_index', 'term', 'df'), file = f) # print 欄位名
118 for term in tf_idf.df.keys(): # 遍歷df中所有的term
119     row += 1
120     tf_idf.df[term]['t_index'] = row # row為t_index
121     print("{:<8} {:<12} {:<8}".format(row, term, tf_idf.df[term]['df']), file = f) # 寫到dictionary.txt
122
```

Result:

```
dictionary.txt
1  t_index term      df
2  1      aan        1
3  2      aaron       2
4  3      ab          1
5  4      aback       1
6  5      abahd       1
7  6      abandon    39
8  7      abat        1
9  8      abc         49
10 9      abcnew      3
11 10     abdallah    2
12 11     abdel       3
13 12     abdomin     2
```

處理邏輯

Result:

output > 1.txt		
	t_index	tf-idf
1	68	0.05247208225914908
2	210	0.04012780635400542
3	344	0.020018078667969143
4	862	0.07636004196512203
5	957	0.047726523425037436
6	974	0.28826986983032116
7	1028	0.0534635531655535
8	1100	0.12510457620112107

- Step 6 : 回答第二題 建立DocID.txt 計算tfidf單位向量

```
123 # (2) Transfer each document into a tf-idf unit vector.
124
125
126 for i in range(1, tf_idf.num_docs+1): #處理從第1篇~第1095篇文章
127
128
129     tf_id_list = []
130     tfidf_list = []
131     length = 0 #計算長度用，為了將tfidf轉為單位向量
132
133     for term in sorted(set(tf_idf.token_list[i])): #遍歷doc[i]的set(token_list[i])
134         t_index = tf_idf.df[term]['t_index'] #取出dictionary.txt中的term其t_index
135         tfidf = tf_idf.tf_idf(i, term) #計算此term在doc[i]的tfidf值
136         tf_id_list.append(t_index)
137         tfidf_list.append(tfidf)
138         length += tfidf * tfidf
139     # 轉為unit vector tfidf_unit_vector:[{2:0.025, 3:0.004, ...},{1:0.001, 5:0.147, ...}, ...]
140     tf_idf.tfidf_unit_vector.append({tf_id_list[j]: tfidf_list[j]/ math.sqrt(length) for j in range(len(tf_id_list))})
141
142     #write to output
143     path = './output'+"/"+str(i)+".txt"
144     f = open(path, 'w')
145     print("{:<8} {:<8}".format('t_index', 'tf-idf'), file = f) # print 欄位名
146     for t_index, tfidf in tf_idf.tfidf_unit_vector[i-1].items(): # -1因為單位向量從index=0開始存
147         print("{:<8} {:<8}".format(t_index, tfidf), file = f) #寫到./output/[i].txt
148
```

Call tf_idf method 計算tf-idf

```
94 def tf_idf(self, index, word):
95     return self.tf[index-1][word]*self.idf[word]
```

處理邏輯

Result:

```
請輸入你想計算哪兩篇Documents的cosine similarity
第一篇(輸入一個數字): 1
第二篇(輸入一個數字): 2
0.20220145913002788
```

• Step 7 : 回答第三題 計算cosine similarity

```
150 # (3) returns cosine similarity of DocX and DocY
151 print("請輸入你想計算哪兩篇Documents的cosine similarity")
152 x = int(input('第一篇(輸入一個數字):'))
153 y = int(input('第二篇(輸入一個數字):'))
154 tfidf_x = tf_idf.tfidf_unit_vector[x-1]
155 tfidf_y = tf_idf.tfidf_unit_vector[y-1]
156
157 print(tf_idf.cosine_similarity(tfidf_x, tfidf_y))
```

Call cosine_similarity method 計算DocX&DocY的cosine similarity

邏輯:

假設DocX和DocY的tfidf unit vector 分別為下表
則只需要從將有同時出現在兩者的term其tf-idf互乘即可

```
98 def cosine_similarity(self, v1, v2):
99     sum = 0
100
101     for x_id in v1.keys():
102         if x_id in v2.keys():
103             sum+= v1[x_id]*v2[x_id]
104     return sum
```

t_index	tf-idf	t_index	tf-idf
25	0.025	21	0.0008
55	0.15	48	0.158
69	0.003	55	0.06
102	0.155	158	0.005
455	0.044	455	0.157

DocX

DocY

ans=
 $0.15*0.06+0.044*0.157$